



Universidade do Estado do Rio de Janeiro

Centro de Tecnologia e Ciências

Faculdade de Engenharia

Lucas Thimoteo

Melissa Costa

**Previsão dos indicadores coletivos de continuidade através de
modelos baseados em redes neurais e modelos estatísticos**


Rio de Janeiro

2018

Lucas Thimoteo

Melissa Costa

**Previsão dos indicadores coletivos de continuidade através de modelos
baseados em redes neurais e modelos estatísticos**



Trabalho de Conclusão de Curso apresentado, como requisito parcial para obtenção do título de Graduado em Engenharia Elétrica, à Faculdade de Engenharia, da Universidade do Estado do Rio de Janeiro. Área de concentração: Sistemas de Potência.

Orientador: Prof. D.Sc. Leonardo Alfredo Forero Mendoza

Coorientador: Prof. D.Sc. Harold Dias de Mello Junior

Rio de Janeiro

2018

CATALOGAÇÃO NA FONTE
UERJ / REDE SIRIUS / BIBLIOTECA CTC/D

D979 Thimoteo, Lucas; Costa, Melissa
Previsão dos indicadores coletivos de continuidade através de modelos baseados em redes neurais e modelos estatísticos / Lucas Thimoteo/ Melissa Costa. – Rio de Janeiro, 2018-
55 f.

Orientador: Prof. D.Sc. Leonardo Alfredo Forero Mendoza
Trabalho de Conclusão de Curso (Graduação) – Universidade do Estado do Rio de Janeiro, Faculdade de Engenharia, Faculdade de Engenharia, 2018.

1. DEC.. 2. FEC.. 3. Redes Neurais.. I. Prof. D.Sc. Leonardo Alfredo Forero Mendoza. II. Universidade do Estado do Rio de Janeiro. III. Faculdade de Engenharia. IV. Título

CDU 02:141:005.7

Autorizo, apenas para fins acadêmicos e científicos, a reprodução total ou parcial desta trabalho de conclusão de curso, desde que citada a fonte.

Assinatura

Data

Assinatura

Data

RESUMO

THIMOTEO, L.T; COSTA, M.C. *Previsão dos indicadores coletivos de continuidade através de modelos baseados em redes neurais e modelos estatísticos*. 2018. 55 f. Trabalho de Conclusão de Curso (Graduação em Engenharia Elétrica) – Faculdade de Engenharia, Universidade do Estado do Rio de Janeiro, Rio de Janeiro, 2018.

No decorrer do século XX, tornou-se maior a dependência da eletricidade para a execução da maioria das atividades nos setores industrial, comercial e residencial. Para garantir os níveis de qualidade de serviço das empresas distribuidoras aos consumidores, a ANEEL estipula limites anuais de indicadores coletivos de continuidade a cada revisão tarifária da concessionária. As concessionárias, por outro lado, buscam oferecer o melhor serviço com o menor custo possível. Logo, é de interesse das concessionárias entender as variáveis que afetam na qualidade de serviço, assim como monitorar os níveis dos indicadores de continuidade e executar melhorias no sistema de maneira otimizada, para mitigar as perdas no faturamento por interrupção no fornecimento de energia elétrica. Este trabalho teve como objetivo estudar o comportamento histórico dos indicadores coletivos de continuidade e propor modelos para prever os valores futuros dos mesmos, em um horizonte de um ano, de maneira que esta previsão possa auxiliar na tomada de decisão do planejamento do sistema de distribuição. Os modelos utilizados para previsão foram baseados em redes neurais perceptron multicamada e no modelo estatístico ARIMA. Como dados de entrada, foram utilizadas as apurações mensais dos indicadores da Light SESA, empresa responsável pela concessão de distribuição de energia elétrica da maior parte da região metropolitana do estado do Rio de Janeiro. As previsões foram comparadas com os dados históricos através do erro absoluto médio percentual e da raiz do erro quadrático médio. Ambos os modelos obtiveram erro absoluto médio percentual de aproximadamente 40% e raiz do erro quadrático médio de aproximadamente 0,3. O modelo ARIMA porém, se mostra levemente superior em algumas ocasiões.

Palavras-chave: DEC. FEC. Redes Neurais. Séries Temporais.

ABSTRACT

THIMOTEO, L.T; COSTA, M.C. . 2018. 55 f. Trabalho de Conclusão de Curso (Graduação em Engenharia Elétrica) – Faculdade de Engenharia, Universidade do Estado do Rio de Janeiro, Rio de Janeiro, 2018.

Throughout 20th century, most of activities in the industry, commercial and residential sectors became more dependent on electricity. To ensure distribution company's quality of service to consumers, the Brazilian National Agency of Electrical Energy stipulates annual limits for collective continuity indicators on every concessionaire tariff revision. On the other hand, concessionaires seek to offer the best service at the least cost. Therefore, it is in the interest of these companies to understand the variables that affect quality of service, as well as monitor collective continuity indicators levels and also execute optimized improvements in the system, to mitigate revenue losses due to electricity supply interruption. This work aims to study the historical behavior of collective continuity indicators and propose models to predict their future values, within an one year horizon, so that this prediction can ancilliate the decision making process when planning the distribution system. Utilized models consisted on Artificial Neural Networks and also ARIMA statistical models. Input data consisted on monthly values of Light SESA collective indicators. This company is responsible for the concession of electricity distribution on most of the metropolitan region of Rio de Janeiro state. Predictions were compared to historical data through the root mean squared error and the median absolute percentage error. Both models obtained approximately 40% of median absolute percentage error and 0,3 of root mean squared error. However, the ARIMA model shows slightly superior results in some occasions.

Keywords: Interruption Duration Equivalent Index. Interruption Frequency Equivalent Index. Artificial Neural Networks. Time Series.

LISTA DE FIGURAS

Figura 1	- Exemplo de série temporal	28
Figura 2	- Neurônio artificial	33
Figura 3	- Rede <i>feedforward</i> camada única	34
Figura 4	- Rede neural <i>Multilayer Perceptron</i>	36
Figura 5	- Sistema Proposto	38
Figura 6	- Área de concessão da empresa Light SESA	40
Figura 7	- Indicador DEC de Janeiro de 2000 a Dezembro de 2017	40
Figura 8	- Indicador FEC de Janeiro de 2000 a Dezembro de 2017	41
Figura 9	- Indicador DEC de Janeiro de 2011 a Dezembro de 2017	42
Figura 10	- Indicador FEC de Janeiro de 2011 a Dezembro de 2017	42
Figura 11	- Técnica de janelamento para redes neurais	44
Figura 12	- Comparação entre a previsão com o Modelo ARIMA e os valores reais do indicador DEC	46
Figura 13	- Comparação entre a previsão com o Modelo ARIMA e os valores reais do indicador DEC - intervalo de 2013 a 2017	47
Figura 14	- Comparação entre a previsão com o Modelo ARIMA e os valores reais do indicador FEC	47
Figura 15	- Comparação entre a previsão com o Modelo ARIMA e os valores reais do indicador FEC - intervalo de 2013 a 2017	48
Figura 16	- Comparação entre previsão com a rede MLP e os valores reais do indi- cador DEC	48
Figura 17	- Comparação entre previsão com a rede MLP e os valores reais do indi- cador FEC	49
Figura 18	- Comparação entre previsão com a rede MLP e os valores reais do indi- cador DEC - intervalo de 2013 a 2017	49
Figura 19	- Comparação entre previsão com a rede MLP e os valores reais do indi- cador FEC - intervalo de 2013 a 2017	50

LISTA DE TABELAS

Tabela 1	- Previsão do modelo ARIMA	47
Tabela 2	- Previsão do modelo de Redes Neurais	50
Tabela 3	- Comparação entre Previsões DEC	50
Tabela 4	- Comparação entre Previsões FEC	51

LISTA DE ABREVIATURAS E SIGLAS

ACF	<i>Auto Correlation Function</i> - Função de Auto Correlação
ACS	<i>Ant Colony System</i> - Sistema de Colônia de Formigas
ANEEL	Agência Nacional de Energia Elétrica
AR	<i>Auto Regressive</i> - Modelo Auto-Regressivo
ARIMA	<i>Auto Regressive Integrate Moving Average</i> - Modelo Auto-Regressivo Integrado de Médias Móveis
ARMA	<i>Auto Regressive Moving Average</i> - Modelo Auto-Regressivo de Médias Móveis
DEC	Duração Equivalente de Interrupção por Unidade Consumidora
DIC	Duração de Interrupção por Unidade Consumidora
DICRI	Duração da Interrupção Individual ocorrida em Dia Crítico por Unidade Consumidora
DMIC	Duração Máxima de Interrupção Contínua por Unidade Consumidora
DNAEE	Departamento Nacional de Águas e Energia Elétrica
DRC _E	Duração Relativa para Tensão Crítica
DRP _E	Duração Relativa da Transgressão para Tensão Precária
END	Energia Não Distribuída
FEC	Frequência Equivalente de Interrupção por Unidade Consumidora
FIC	Frequência de Interrupção por Unidade Consumidora
GA	<i>Genetic Algorithm</i> - Algoritmo Genético
MAIFI	<i>Monetary Average Interruption Frequency Index</i> - Índice Monetário Médio de Frequência de Interrupção
MLP	<i>Multilayer Perceptron</i> - Perceptron Multicamada
MA	<i>Moving Average</i> - Modelo de Médias Móveis
MT	Média Tensão
RNA	Redes Neurais Artificiais
PACF	<i>Partial Auto Correlation Function</i> - Função de Auto Correlação Parcial
PRODIST	Procedimentos de Distribuição de Energia Elétrica no Sistema Elétrico Nacional
SAIDI	<i>System Average Interruption Duration Index</i> - Índice Médio de Duração de Interrupção do Sistema
SAIFI	<i>System Average Interruption Frequency Index</i> - Índice Médio de Frequência de Interrupção do Sistema
SISPAI	Sistema Integrado de Planejamento Agregado de Investimentos
SMC	Simulação de Monte Carlo
SQS	<i>Security and Quality of Supply</i> - Segurança e Qualidade de Fornecimento
TAROT	Tarifa Otimizada

SUMÁRIO

1	INTRODUÇÃO	9
1.1	Introdução	9
1.2	Motivação	11
1.3	Objetivo	12
1.4	Estrutura Capítular	12
2	QUALIDADE DE ENERGIA E INDICADORES DE CONTI- NUIDADE	13
2.1	Indicadores de Continuidade	13
2.2	Metas para Indicadores de Continuidade	15
2.3	Melhoria dos Indicadores de Continuidade	16
3	REVISÃO DE LITERATURA	19
3.1	Planejamento de Confiabilidade em Redes de Distribuição	19
3.2	Alocação de Recursos para Planejamento e Manutenção de Redes de Distribuição	22
3.3	Planejamento de Redes de Distribuição Baseado em Métodos de Inteligência Computacional	24
4	SÉRIES TEMPORAIS	27
4.1	Modelos de Previsão de Séries Temporais	28
5	REDES NEURAIIS ARTIFICIAIS	32
5.1	Modelagem Cognitiva de uma Rede Neural Artificial	33
5.2	Taxonomia de Redes Neurais Artificiais	35
5.2.1	<u>Rede Neural Perceptron Multicamada</u>	36
5.3	Processo de Aprendizagem e Desempenho de uma Rede Neural	36
6	METODOLOGIA	38
6.1	Interpretação Inicial do Conjunto de Dados	39
6.2	Análise Preliminar dos Indicadores Mensais DEC e FEC	39
6.3	Configuração do Modelo ARIMA	43
6.4	Configuração da Rede Neural MLP	43
6.5	Avaliação de Resultados	45
7	RESULTADOS	46
7.1	Resultados do Modelo ARIMA	46
7.2	Resultados do Modelo de Redes Neurais	48
7.3	Comparação entre os modelos	50
8	CONCLUSÕES	52
	REFERÊNCIAS	53

1 INTRODUÇÃO

1.1 Introdução

No decorrer do século XX, com a crescente expansão do fornecimento de energia elétrica, tornou-se maior a dependência da eletricidade para a execução da maioria das atividades dos setores industrial, comercial e residencial. Em uma fase inicial, mostra-se mais importante a medição da continuidade do serviço de fornecimento de energia elétrica. Com a evolução de diversos sistemas tecnológicos no setor industrial, como por exemplo a expansão do controle e automação de processos industriais, e também no setor comercial como a utilização de sistemas de vigilância, controle de estoque, fluxo de caixa e também sistemas de transmissão de dados (principalmente no setor de comunicação), preocupa-se também com a qualidade da energia elétrica em si.

É de interesse comum entre as empresas geradoras, transmissoras e distribuidoras de energia elétrica monitorar seus níveis de continuidade e qualidade de serviço para que possam oferecer o melhor serviço com o menor custo possível.

Até a década de 1970, as distribuidoras de energia elétrica utilizavam seus dados históricos de frequência e duração das interrupções de fornecimento de energia elétrica, para projetar melhorias no setor elétrico (CYRILLO, 2011). Neste cenário, ainda não havia um órgão governamental responsável por regular e fiscalizar as empresas e o termo “qualidade de energia” não era de definição única no Brasil. Consequentemente, não havia parâmetros de fiscalização para melhoria da qualidade de fornecimento de energia.

Para garantir a qualidade e continuidade do fornecimento de energia elétrica das empresas ao consumidor, foram criados indicadores de qualidade e continuidade, primeiramente definidos na Portaria 46/1978 (DNAEE, 1978). Estes seriam os primeiros indicadores de âmbito nacional.

Devido a problemas com a crise financeira na década de 80, os investimentos no setor elétrico brasileiro, que até então era totalmente estatal, foram interrompidos. Fatores como desobediência civil das concessionárias regionais ao órgão regulador e à Constituição Federal de 1988 e também o aumento da força política de grandes consumidores (que pressionavam pela redução de tarifas), levaram ao endividamento e à inviabilidade do setor elétrico naquele momento (DIEESE, 2017). Para tentar corrigir a situação, as empresas do setor elétrico foram privatizadas em meados de 1992 durante o governo do presidente Fernando Henrique Cardoso.

Em 1995, foi criada a “Lei das Concessões” (Brasil, 1995) que estabelecia que cada distribuidora de energia só poderia oferecer serviços para clientes da sua área de concessão. Foram regulamentados diversas normas quanto a tarifação, licitação, área de concessão e definição de serviço adequado para manter e até mesmo melhorar a qualidade de serviço

de distribuição de energia. Em 1997, a Agência Nacional de Energia Elétrica (ANEEL) foi criada e, juntamente com outros órgãos estaduais, passou a exercer o papel regulador e fiscalizador das concessionárias para que se cumpram os compromissos e obrigações assumidos (DIAS, 2002).

A principal função de regulação no setor elétrico é buscar otimizar o bem estar social da atividade econômica presente neste mercado. O regulador pode gerir a qualidade de energia por métodos de comparação entre empresas similares, como também através da regulamentação da continuidade do fornecimento de energia através de indicadores de continuidade.

Os indicadores de continuidade estão relacionados a qualidade do serviço prestado pela empresa distribuidora. No Brasil, estes indicadores estão definidos no Módulo 8 dos Procedimentos de Distribuição (PRODIST), que visa estabelecer parâmetros para a qualidade de serviço, qualidade do produto e também qualidade do atendimento das concessionárias (ANEEL, 2018). Eles são divididos entre indicadores coletivos e indicadores individuais. Os indicadores mais relevantes para a apuração da qualidade de serviço são o DEC (Duração Equivalente de Interrupção por Unidade Consumidoras), FEC (Frequência Equivalente de Interrupção por Unidade Consumidora), DIC (Duração de Interrupção por Unidade Consumidora) e FIC (Frequência de Interrupção por Unidade Consumidora).

As exigências feitas pela ANEEL, antes estabelecidas igualmente para todas as concessionárias do país, hoje são estabelecidas de maneira distinta para diversos conjuntos de consumidores dentro uma área de concessão. Uma vez que foi verificado que dentro de uma mesma área de concessão, podem haver divergências quanto a qualidade de serviço fornecido devido a disparidades geográficas, demográficas e de mercado (CYRILLO, 2011). Um conjunto de unidades consumidoras é caracterizado por fatores como potência instalada, densidade de carga, área, entre outros, que estão definidos no Módulo 8 do PRODIST. Vale ressaltar que a caracterização de um conjunto está intimamente ligada as características geográficas e socioeconômicas do local. Assim, são propostos limites globais para a concessionária e também limites exclusivos a cada conjunto de unidades consumidoras situados na área de concessão. Os limites propostos são atualizados periodicamente a cada revisão tarifária da concessionária.

O objetivo da ANEEL ao estabelecer metas (limites) para cada distribuidora é equalizar e melhorar a qualidade de serviço fornecido pelas empresas. Desta forma, são propostas novas metas que possam incentivar as empresas a investirem na melhoria contínua de seu sistema de distribuição. Por consequência, algumas distribuidoras que antes não possuíam problemas para controlar as metas estabelecidas, terão que se esforçar mais para atingir as metas e não sofrerem penalidades e multas.

Até 2009, caso as distribuidoras ultrapassassem os limites, receberiam multas. Tais multas poderiam ser aplicadas em favor da ANEEL, ou do consumidor. A partir de 2010, a ANEEL extinguiu as multas por transgressão dos indicadores e determinou que a con-

cessionária deve compensar diretamente os consumidores caso ocorra a transgressão dos limites dos indicadores de continuidade. Apesar das multas por transgressão terem sido extinguidas, a ANEEL pode requisitar subsídios das concessionárias para a programação das fiscalizações. Esta medida também foi criada de maneira a incentivar as concessionárias a buscarem melhorias para suas redes e para o serviço prestado.

Contudo, é importante ressaltar que eventuais multas e ressarcimentos podem não ser suficientes para contrabalancear os impactos negativos sofridos pelo consumidor. Estes impactos, também denominados de custos de interrupção, atingem todos os tipos de consumidores (industrial, comercial e residencial). Por exemplo, na interrupção do fornecimento, pode haver perda de materiais em transformação durante processos industriais, impossibilidade de efetuação de vendas nos diversos setores comerciais, perda de horas de trabalho, perda de bem-estar, desconforto e também em casos de hospitais, a interrupção no fornecimento pode por em risco a vida de seus pacientes. Assim, é importante buscar estratégias que possam beneficiar tanto as concessionárias quanto o consumidor, de maneira que seja encontrado um equilíbrio no bem estar financeiro e social.

Levando-se em consideração os aspectos apresentados, nota-se que é de extrema importância para as empresas distribuidoras buscarem métodos para melhorar a qualidade de seu serviço prestado. Estes métodos, majoritariamente provêm do planejamento tanto das redes de distribuição (modernização de equipamentos, melhoria de infraestrutura, investimento em mais equipes de manutenção), quanto dos investimentos diretos e indiretos (pesquisas e desenvolvimento de novas estratégias) que poderão ser efetuados a médio e longo prazo. Através do planejamento para a expansão e melhoria do sistema, as distribuidoras buscam aumentar a confiabilidade do sistema, tentando maximizar seus lucros e reduzir seus custos.

Além da execução do planejamento para a melhoria dos indicadores de continuidade, podem ser utilizadas estratégias para auxiliar na tomada de decisão tanto para a elaboração do planejamento quanto para a execução do mesmo. Por exemplo, a utilização de métodos de inteligência computacional pode ser implementada de maneira que os indicadores de continuidade possam ser estimados dentro de um horizonte desejado. Com o conhecimento de possíveis valores futuros, pode ser efetuado um planejamento mais consciente, mais inteligente e que evite que a empresa tenha gastos desnecessários.

1.2 Motivação

De uma maneira geral, pode-se afirmar que as políticas para o cumprimento dos limites aceitáveis dos indicadores de qualidade de serviço se tornaram mais rígidas. Isto pode levar as concessionárias a investirem mais em melhorias para seus respectivos sistemas de maneira a manterem seus indicadores abaixo dos limites estabelecidos a maior

parte do tempo.

Sendo assim, tal tema é de importância na área da Engenharia Elétrica e nos motiva a estudar sobre o assunto, nos atualizarmos e apresentarmos soluções para que as concessionárias possam se adequar aos novos acordos e atingir as metas propostas.

1.3 Objetivo

Este trabalho tem como objetivo auxiliar no planejamento de redes de distribuição através da previsão dos indicadores DEC e FEC em uma determinada área de concessão. A área de concessão escolhida para estudo pertence a Light SESA, que efetua a distribuição de energia elétrica em grande parte da região metropolitana do estado do Rio de Janeiro.

Através de modelos de previsão baseados em redes neurais, iremos propor um modelo que poderá auxiliar no processo de tomada de decisão para que os indicadores de continuidade estejam abaixo dos limites estipulados pela ANEEL. Consequentemente, a qualidade do serviço de fornecimento de energia elétrica será melhorada, evitando assim possíveis penalidades à concessionária e maximização de seus lucros.

Os objetivos secundários deste trabalho constituem os seguintes:

- Analisar o perfil dos indicadores DEC e FEC da Light, durante os anos, sob a perspectiva de séries temporais.
- Entender as variações do DEC e FEC durante os meses do ano.
- Identificar as variáveis relevantes que podem impactar nos níveis dos indicadores.
- Modelar uma rede neural artificial em multicamadas e comparar seu desempenho com outros métodos clássicos de previsão de dados.
- Discutir os resultados apresentados.
- Propor trabalhos futuros.

1.4 Estrutura Capítular

Este trabalho tem a seguinte estrutura capitular:

2 QUALIDADE DE ENERGIA E INDICADORES DE CONTINUIDADE

Segundo a ANEEL, uma empresa distribuidora pode ser avaliada, entre diversos fatores, sob a ótica da qualidade de serviço prestado e da qualidade do produto fornecido. A qualidade do produto consiste na avaliação da conformidade da forma de onda de tensão, perturbações na forma de onda de tensão, fator de potência, variação de frequência e presença de harmônicos na rede. A qualidade de serviço, consiste na avaliação das interrupções de fornecimento de energia elétrica e também na avaliação dos tempos de atendimento.

Para o consumidor, a interrupção do serviço de fornecimento de energia elétrica é sempre evidente e implica em transtorno de alguma ordem. Porém, a qualidade da energia consumida nem sempre é perceptível, pois quando há algum tipo de distúrbio na energia, este normalmente somente é percebido quando ocasionalmente falhas no funcionamento de dispositivos e equipamentos (MEHL, 2001). Assim, a qualidade de energia mostra-se mais evidente quando resulta em interrupções no serviço de fornecimento. Da mesma forma, com o avanço tecnológico de equipamentos eletroeletrônicos de medição em residências, comércios e indústrias, outros fatores além da continuidade passam ser avaliados sob a ótica do consumidor.

2.1 Indicadores de Continuidade

Estes indicadores são os principais avaliadores da qualidade de serviço prestado por uma distribuidora. Eles podem ser divididos em indicadores individuais e coletivos. De acordo com a seção 8.2 do Módulo 8 do PRODIST, interrupções no fornecimento com duração abaixo de 3 minutos não são contabilizadas para o cálculo dos indicadores de continuidade pois este é o tempo máximo de religamento manual de linhas de transmissão caso o religamento automático esteja desativado.

Os indicadores individuais são obtidos através de medições diretas feitas para a cada unidade consumidora dentro da área de concessão e são fornecidos na fatura mensal do consumidor. Eles são: DIC, FIC, DMIC e DICRI.

O indicador DIC (Duração de Interrupção por Unidade Consumidora) contabiliza a duração de uma interrupção de fornecimento de energia elétrica a uma unidade consumidora ou ponto de conexão, dentro de uma janela de tempo estipulada. Este indicador é contabilizado em horas e é apresentado a seguir:

$$DIC = \sum_{i=1}^n t(i) \quad (1)$$

Onde:

i = número de interrupções de 1 a n ,

$t(i)$ = tempo de duração de cada interrupção da unidade consumidora, em horas.

O indicador FIC (Frequência de Interrupção por Unidade Consumidora) contabiliza quantas vezes houve interrupção no fornecimento de energia elétrica a uma unidade consumidora ou ponto de conexão, dentro de uma janela de tempo estipulada. Este indicador é expresso em número de interrupções e é apresentado a seguir:

$$FIC = n \quad (2)$$

Onde:

n = número de interrupções de longa duração.

Já o indicador DMIC (Duração Máxima de Interrupção por Unidade Consumidora) estipula um limite máximo de interrupção contínua para uma unidade consumidora ou ponto de conexão. Este indicador é contabilizado em horas e é apresentado a seguir:

$$DMIC = t(i)_{\max} \quad (3)$$

O indicador DICRI (Duração da Interrupção Individual ocorrida em Dia Crítico por Unidade Consumidora) contabiliza a duração de uma interrupção que ocorre em um dia crítico. A definição de dia crítico se encontra no Módulo 1 do PRODIST. Este indicador é contabilizado em horas e é apresentado a seguir:

$$DICRI = t_{\text{crítico}} \quad (4)$$

Os indicadores coletivos, são apurados por conjunto de unidades consumidoras. Estes são: DEC e FEC.

O indicador DEC (Duração Equivalente de Interrupção por Unidade Consumidora) contabiliza a média do número de horas que um consumidor esteve sem energia elétrica durante um período de tempo, para um dado conjunto de unidades consumidoras. Este indicador pode ser calculado por:

$$DEC = \frac{\sum_{i=1}^n Ca(i) * T(i)}{Cs} \quad (5)$$

Onde:

i = número de interrupções de 1 a n ,

$T(i)$ = tempo de duração de cada interrupção do conjunto considerado, em horas,
 $Ca(i)$ = número de consumidores atingidos do conjunto considerado,
 Cs = número total de consumidores do conjunto considerado.

O indicador FEC (Frequência Equivalente de Interrupção por Unidade Consumidora) contabiliza a quantidade de vezes, em média, que houve interrupção de fornecimento em uma unidade consumidora. Este pode ser calculado por:

$$FEC = \frac{\sum_{i=1}^n Ca(i)}{Cs} \quad (6)$$

Onde:

i = número de interrupções de 1 a n ,

$Ca(i)$ = número de consumidores atingidos do conjunto considerado,

Cs = número total de consumidores do conjunto considerado.

Os indicadores coletivos encontram-se disponíveis publicamente para consulta no site da ANEEL. É possível consultar os indicadores coletivos globais de cada concessionária, como também os indicadores coletivos de cada conjunto de consumidores. Os intervalos para consulta podem ser mensais ou anuais.

2.2 Metas para Indicadores de Continuidade

A ANEEL estipula metas para os indicadores individuais e coletivos a fim de manter e melhorar a qualidade do serviço prestado.

Para os indicadores individuais, são estipuladas metas mensais, trimestrais e anuais. Na seção Anexo I do Módulo 8 do PRODIST, podem ser encontradas tabelas para as metas dos indicadores individuais. Cada unidade consumidora possui metas de indicadores individuais que variam de acordo com o conjunto de unidades consumidoras em que a mesma se encontra. Caso a apuração de algum destes indicadores esteja acima do limite estipulado no período vigente, o consumidor deverá ser compensado através de um abate no valor de sua fatura, proporcionalmente ao limite extrapolado. São feitas compensações mensais, trimestrais e anuais para cada consumidor.

Para os indicadores coletivos a ANEEL estipula metas anuais distintas para a concessionária, tendo como horizonte o intervalo entre cada revisão tarifária da concessionária. É importante destacar que as metas para os indicadores coletivos são propostas através da comparação de desempenho (*benchmarking*) de redes de distribuição de características similares e também outros fatores que são apresentados no Módulo 8 do PRODIST. Assim, cada conjunto de unidades consumidoras possui metas distintas que provêm da análise de suas características. Estas características são: Área do conjunto, extensão da rede

MT (média tensão) urbana e rural, energia consumida por potência instalada, número de unidades consumidoras total, consumo médio por tipo de classe (residencial, comercial e industrial) e percentual de unidades consumidoras por classe.

A partir da publicação das metas pela ANEEL, a concessionária tem direito a se manifestar a respeito dos valores calculados, sendo possível a obtenção de um acordo entre a ANEEL e a concessionária.

São feitas apurações mensais, trimestrais e anuais dos indicadores coletivos por parte das distribuidoras e estes dados são repassados a ANEEL para a verificação da continuidade do serviço prestado. Caso a meta anual estipulada não seja cumprida, isto é, o limite de algum indicador seja extrapolado, a concessionária não recebe uma multa direta, porém pode subsidiar a ANEEL para a programação das fiscalizações.

Como exemplo, na Nota Técnica (ANEEL, 2013), são apresentados pela ANEEL os limites de DEC e FEC estabelecidos para a empresa Light, para o período de 2014 a 2018. São abordados os motivos e justificativas para a proposta dos limites e é feita uma análise comparativa do desempenho da Light com outras empresas da região sudeste como CPFL, CEMIG e Eletropaulo. Em contrapartida, a Light alega que as metas propostas pela ANEEL não capturam a caracterização de seus conjuntos de unidades consumidoras, levando ao distanciamento entre as metas e a capacidade de ação da concessionária para a atingir os níveis de indicadores estipulados.

Assim, pode-se dizer que em certas vezes, os modelos matemáticos utilizados para a obtenção das metas para os indicadores de continuidade, não fidelizam características situacionais que podem influenciar na continuidade do fornecimento de energia elétrica.

2.3 Melhoria dos Indicadores de Continuidade

Como mencionado anteriormente, é de interesse comum entre as distribuidoras e os consumidores que haja melhoria contínua no serviço de fornecimento. Como a qualidade de serviço está intimamente ligada a continuidade do fornecimento de energia elétrica, é importante que se busquem estratégias para minimizar as interrupções de fornecimento na rede de distribuição.

As interrupções que ocorrem numa rede de distribuição podem ser de natureza programada ou não-programada, e de origem interna ou externa do circuito. O Anexo II do Módulo 8 - PRODIST apresenta todas as classificações possíveis para os eventos de distúrbios na rede (interrupções no fornecimento e perturbações na forma de onda de tensão).

As interrupções programadas podem ocorrer para fins de manobra, manutenção ou melhorias do sistema. Sendo assim, é importante para a concessionária que essas interrupções sejam pontuais e rápidas para que não ocorra o risco de futuras compensações

ao consumidor devido as interrupções.

As interrupções do tipo não-programadas provém de diversos eventos aleatórios, ou seja, que não são previstos. Podemos citar alguns deles: descargas atmosféricas, falhas em equipamentos, falhas em sistemas de proteção e religamento, acidentes, interferências de vegetação ou animais, poluição, vandalismo e roubo de fiação e equipamentos.

Destaca-se também que o furto de energia por parte das unidades consumidoras pode contribuir para interrupções no fornecimento de energia de uma certa área. Isto se deve porque ao passo que o furto de energia ocorre, a concessionária tem dificuldades de dimensionar corretamente a rede, manter a integridade da mesma e também fica impossibilitada de monitorar o perfil de carga real de um conjunto de consumidores. Sendo essa perspectiva colocada de uma maneira coletiva, quanto mais essa situação é propagada através da sociedade, maiores são os impactos negativos sobre a qualidade de serviço prestada pelas concessionárias.

Além disso, devido ao fato de que a maior parte das redes de distribuição no Brasil são do tipo aéreo, essas sofrem muitas interferências do meio em que se encontram. Apesar de seu custo de instalação ser mais barato que uma rede subterrânea, seus custos de manutenção são bem mais elevados e conseqüentemente, a probabilidade de interrupções devido a interferências aumenta consideravelmente. Em áreas urbanas por exemplo, é frequente a ocorrência de interrupções devido a interferência de árvores plantadas ao longo das vias.

Também é importante mencionar que as concessionárias encontram dificuldades em executar manutenções em certas áreas. Estas áreas, que são denominadas áreas de difícil acesso ou acesso limitado ou restrito, por motivos adversos, apresentam diversos obstáculos para a execução das atividades de manutenção e por consequência, sofrem com um elevado número de interrupções no fornecimento, que quase sempre se encontram acima dos limites estipulados pela ANEEL, quando comparadas com outras áreas dentro de uma mesma área de concessão. Estas áreas podem ser caracterizadas por trechos de propriedades particulares, áreas protegidas pelo meio ambiente ou também podem ser áreas urbanas de difícil acesso (geralmente devido a altos índices locais de violência ou urbanização precária). É de costume das distribuidoras argumentarem com a ANEEL, maiores valores limites dos indicadores DEC e FEC para as áreas de difícil acesso. Por exemplo, nesta nota técnica da ANEEL (ANEEL, 2013), a Light SESA argumenta que sua área de concessão possui 39 % conjuntos considerados heterogêneos e solicita maiores limites de DEC e FEC para sua área de concessão.

Pode-se afirmar que, em razão do que foi apresentado, muitos destes fatores estão fora do alcance de monitoramento e controle da concessionária. Porém, ainda assim é possível que sejam tomadas atitudes, por parte da concessionária, para mitigar a frequência e duração das interrupções no fornecimento de energia elétrica. Por exemplo, a instalação de redes primárias compactas ou isoladas em trechos muito arborizados pode diminuir con-

sideravelmente as chances de ocorrências de interrupção por interferência da vegetação. Também, para áreas que apresentam sobre-cargas, podem ser inseridos mais transformadores entre a rede primária e secundária. Ainda, a automação da rede de distribuição por inserção de equipamentos com capacidade de religamento, ou técnicas mais sofisticadas como redes *self-healing*, pode trazer o benefício da capacidade de reestabelecimento automático na ocorrência de alguma falha. Já em um escopo social, pode ser implementado algum programa para conscientização da população geral quanto aos danos causados pela prática do furto de energia elétrica.

Podemos concluir que as possibilidades de melhorias na qualidade de serviço são inúmeras. Porém, sempre deve ser levado em consideração qual o custo da estratégia de melhoria e se a mesma é viável.

Portanto, é clara a importância do investimento em técnicas de estudo para a melhoria da rede, seja para o aumento geral de sua eficiência como também para aumentar sua confiabilidade. Podemos citar alguns dos diversos benefícios de buscar a melhoria dos indicadores de continuidade. Entre os quais, destacam-se os seguintes:

- Diminuir a quantia das compensações pagas aos consumidores,
- Aumentar a margem de receita devido a menos interrupções e consequentemente, um maior tempo de fornecimento contínuo,
- Aumentar o nível de satisfação do cliente,
- Aumentar o indicador global de desempenho da concessionária.

3 REVISÃO DE LITERATURA

O planejamento de redes de distribuição é uma tarefa essencial para gerenciar os custos de operação, manutenção, expansão e melhoria do sistema de distribuição como um todo.

O engenheiro deve assegurar minimamente as capacidades de transformação e distribuição visando a previsão de cargas dentro do horizonte de planejamento considerado (KHATOR; LEUNG, 1997).

A seguir serão apresentadas diferentes estratégias que podem auxiliar no planejamento para a expansão, manutenção, confiabilidade e qualidade de energia de redes de distribuição.

3.1 Planejamento de Confiabilidade em Redes de Distribuição

(DIAS, 2002) propôs um modelo para calcular indicadores de qualidade de serviço (DEC, FEC, DIC, FIC) em redes de distribuição primárias e secundárias.

Seu objetivo principal é auxiliar na tomada de decisão para o planejamento de redes de distribuição. Isto é, a partir da análise da configuração atual da rede, pode-se propor melhorias em locais específicos, esperando-se obter melhores indicadores de qualidade de serviço. Para cada configuração proposta, os indicadores são recalculados e assim é possível montar um quadro comparativo de cada cenário. Para a escolha de uma nova configuração são levados em consideração a viabilidade da proposta, dificuldade operacionais, impactos na manutenção e também são realizadas análises econômicas.

Primeiramente, são analisados os tipos de blocos que estão conectados a um alimentador de distribuição. Blocos são áreas separadas por grupo de equipamentos de manobra e seccionadores na rede de distribuição. Na ocorrência de uma falha permanente em um dos blocos da rede, os demais blocos podem ser classificados em:

- Não atingido,
- Restabelecível,
- Transferível,
- Permanentemente interrompido.

Em seguida é feita uma avaliação da classificação dos equipamentos de proteção e como estes afetam a confiabilidade do sistema. Os equipamentos podem ser classificados em:

- com capacidade de religamento e com capacidade de coordenação,
- com capacidade de religamento mas sem capacidade de coordenação,
- sem capacidade de religamento.

Cada equipamento, de acordo com sua classificação, gera impactos nos blocos do sistema quando leva em consideração a quantidade de interrupções permanentes, conforme a metodologia proposta pelo trabalho do (DIAS, 2002).

Com estas classificações, uma matriz de quantidades prováveis de defeitos pode ser construída. Esta matriz avalia o impacto do defeito em um dado bloco, nos demais blocos adjacentes para um alimentador de distribuição. Após, é possível calcular o FEC do alimentador a partir do somatório de todos os seus valores no sentido das colunas da matriz.

De forma similar, o tempo de restabelecimento de cada bloco afetado pela falha é analisado e também leva em consideração a classificação de cada bloco e a classificação dos equipamentos de proteção. Em seguida, é obtida uma matriz com os tempos de interrupção dos blocos, ponderados pelo número de consumidores em cada bloco. O índice DEC pode ser obtido de forma similar ao FEC, somando-se todos os elementos da matriz no sentido das colunas e dividindo o valor pelo número de consumidores totais no alimentador.

A partir das matrizes de quantidades prováveis de defeito e tempos de interrupção entre os blocos em cada caso, pode-se determinar quais blocos possuem o maior impacto na frequência e na quantidade de tempo de defeito permanente da rede como um todo, pois como estes resultados partem de dados históricos, é possível saber efetivamente quais blocos ficaram sem energia.

Com base nestes resultados são feitas proposições como a automação de dispositivos de proteção e seccionamento e a substituição dos tipos de condutores das redes primárias. São obtidas melhorias nos indicadores globais para ambos os casos, porém para o caso da instalação de religadores automáticos há um impacto maior na redução dos mesmos (aproximadamente 20% para o FEC e o END e 5% para o DEC).

Devem ser levados em consideração parâmetros como características geográficas, questões técnicas e econômicas, tempo de execução, etc., para que a capacidade de planejamento seja expandida além da metodologia proposta.

Este estudo da CPFL (DIAS; MANHÃES; OLIVEIRA, 2004) dá continuidade ao que foi proposto anteriormente e implementa o modelo através do software REDE, da CPFL (MANHÃES, 2000), em que o usuário administra a rede em questão através de uma interface gráfica contendo todos os equipamentos de manobra e proteção.

A confiabilidade do sistema é analisada com base em alguns parâmetros, tais como taxa de falhas média por quilômetro de rede por ano, percentual de falhas permanentes e

média de tempos de atendimento por área rural ou urbana. Conhecendo-se os indicadores DEC e FEC da rede em estudo, estes podem ser fornecidos ao programa para que sejam recalculados os tempos de atendimento e as taxas de falhas originalmente fornecidos. Assim, pode ser feita uma análise dos impactos de alteração da rede nos indicadores coletivos de continuidade.

A metodologia, que foi proposta acima, mostra-se útil para auxiliar no planejamento, em alterações e em melhorias de um sistema real, utilizando apenas de dados históricos da própria rede.

Em (HERNANDO-GIL; ILIE; DJOKIC, 2016) é apresentado uma abordagem integrada para planejamento de confiabilidade e estimativa de risco de redes de distribuição ativas através de métodos estocásticos. A rede estudada neste trabalho é uma rede genérica baseada em um padrão tipicamente operado nas redes de distribuição urbanas do Reino Unido.

Hernando-Gil afirma que modelos que não consideram eventos de faltas no lado de baixa tensão da rede de distribuição, frequentemente geram relatórios de desempenho não realistas. Da mesma forma, modelos baseados somente em regressões lineares a partir de históricos de desempenho da rede devem ser evitados, sendo substituídos por simulações probabilísticas.

O modelo proposto é baseado num algoritmo iterativo que tem como parâmetros de entrada perfis de carga, tempo de reparo de equipamentos, taxas de falha, configurações de sistemas de proteção e garantia de requisitos mínimos de fornecimento. A performance do sistema é avaliada através dos seguintes: índice médio de frequência de interrupção do sistema (SAIFI – *system average interruption frequency index*), índice de duração média da interrupção de fornecimento do sistema (SAIDI – *system average interruption duration index*), índice de duração média da interrupção monetária do sistema (MAIFI – *monetary average interruption frequency index*) e um índice de garantia e qualidade de fornecimento de energia (SQS – *security and quality of supply*).

São estudados três cenários distintos: Cenário 1, onde não é considerado o acionamento de fornecimento alternativo ou chaves automáticas que podem atuar entre alimentadores da rede. Cenário 2, onde são simulados três casos distintos com atuação de chaves seccionadoras entre os alimentadores da rede. Por fim, o Cenário 3 leva em consideração a atuação de chaves seccionadoras e o fornecimento alternativo de energia. Este último cenário é considerado uma rede do tipo 'smart grid' com alta flexibilidade e baixo impacto no fornecimento de energia ao consumidor, no qual interrupções de longa duração nos cenários 1 e 2, se tornam interrupções de curta duração, isto é, menores que três minutos, não entrando no cálculo do indicador.

Os resultados obtidos são comparados com valores de indicadores anuais fornecidos pelas distribuidoras do Reino Unido (OFGEM, 2009) e são apresentados em função dos índices SAIDI, SAIFI e MAIFI. É sugerido que as concessionárias considerem para

suas respectivas redes de distribuição, um planejamento que leva em conta a atuação de chaves de manobras automatizadas e a integração com sistemas de fornecimento de energia alternativa, obtendo assim uma rede smart grid pois os indicadores de continuidade desta configuração se mostram bem menores que as demais, sendo a maioria das falhas de curta duração, não agregando para o cálculo de frequência e duração de interrupção de fornecimento de energia.

3.2 Alocação de Recursos para Planejamento e Manutenção de Redes de Distribuição

Em (NUNES, 2016), foi construído um modelo de previsão de indicadores e possível correção da rede elétrica de distribuição, considerando as ações planejadas de manutenção preventiva. O modelo foi elaborado, empregando o aplicativo Microsoft Office Excel a fim de manipular os dados, para prever situações de curto a longo prazos os indicadores coletivos (DEC e FEC). Dessa forma, possibilitando a distribuidora planejar e alocar seus recursos financeiros e realizar as manutenções preventivas e minimizar interrupções de serviço.

Em (TRAGOONTHAI; CHAITUSANEY, 2017), o objetivo principal é estudar a alocação de recursos financeiros destinados as atividades de manutenção da rede, de maneira a minimizar custos monetários, ainda obtendo os índices de confiabilidade desejados pela empresa.

São estudados a alocação de recursos em 12 regiões de 4 áreas geográficas da Tailândia. Os parâmetros para simulação que caracterizam cada área geográfica são dados da rede como relatórios de falhas, custos de cada atividade de manutenção e custos de interrupção de fornecimento.

Os estudos de caso avaliam duas atividades primárias de manutenção: a poda de árvores e patrulhas de manutenção. Monitorar essas atividades se mostra essencial pois de acordo com (PEA, 2014) as mesmas levam a diminuição de perdas por interrupção.

O resultado obtido com esta metodologia pode ser usado como guia para planejamentos de manutenção preventiva visando manter ou até diminuir os indicadores SAIDI, SAIFI, MAIFI e melhorar a qualidade do serviço de fornecimento.

Cyrillo propõe em (CYRILLO, 2011), uma metodologia para o estabelecimento de metas de qualidade na distribuição de energia, através de resultados obtidos pelo software SISPAI (Sistema Integrado de Planejamento Agregado de Investimentos) e da análise da TAROT (Tarifa Otimizada).

Através do planejamento agregado de investimentos é possível consolidar uma relação entre os investimentos feitos numa rede de distribuição e a qualidade de energia. A partir desses resultados pode-se estabelecer os níveis de continuidade desejados, con-

siderando a opinião do consumidor. Por outro lado, a tarifa otimizada busca encontrar a melhor relação econômica entre consumidor e concessionária, mantendo um equilíbrio financeiro de mercado.

O SISPAI procura otimizar os investimentos na rede visando atender a expansão da mesma e seus critérios técnicos exigidos com o menor custo global possível, tendo como seu principal fator de escolha para execução de obras a relação BC (Benefício/Custo). O Custo é caracterizado pelo valor anual de investimento necessário para execução das obras e o Benefício representa os valores dos ganhos econômicos devidos à redução das perdas, índices de continuidade mais altos e melhores valores de tensão.

No SISPAI, é possível estabelecer duas formas de cálculo para obtenção de melhor índices de continuidade. O primeiro caso é a redução dos valores permitidos de DEC e FEC para toda a rede. Nesta situação há o risco de se realizar investimentos que atendam apenas aos indicadores de qualidade, oferecendo soluções pouco econômicas. Há também o risco de estabelecimento de metas de índices que são incoerentes com os padrões de rede utilizados. O segundo caso é aumentar o valor unitário da END, de maneira a aumentar o custo social da energia não distribuída (C_{END}) para que seja possível executar investimentos de expansão e de qualidade na rede.

A análise da tarifa otimizada (TAROT) é um dos métodos que permite a avaliação entre a relação do nível tarifário e os custos de uma concessionária, levando em conta as revisões tarifárias estipuladas pelo Regulador. Este modelo possibilita a otimização dos investimentos baseados nos custos da distribuidora e no benefício social recebido pelo consumidor. É equacionado a relação entre o valor da qualidade de energia para o consumidor e os custos decorrentes para manutenção e expansão de uma rede de distribuição, atendendo aos parâmetros de qualidade desejados.

A rede elétrica de distribuição escolhida para o estudo de caso foi uma área da região de concessão da AES Eletropaulo, a Regional Oeste, que se encontrava em expansão na época do estudo e possuía valores de indicadores abaixo da média global da empresa.

Primeiramente, o estudo de caso foi realizado para o SISPAI e através do aumento do valor unitário de energia não distribuída, o software decide qual será a política de obras para melhoria dos índices de qualidade, baseando-se em resultados econômicos. Assim, foi proposto um horizonte de planejamento de 10 anos, com uma taxa de atualização dos investimentos de 10% do valor presente líquido, com intervalos para análise de investimento e impacto nos indicadores de um, quatro e dez anos. Foram adotados valores de Energia Não Distribuída (END) de 1 a 15 R\$/KWh. Dentro dos resultados obtidos, pode-se destacar que para um valor de END de 10, é obtido um DEC menor que 8h por ano e um FEC menor que 4 vezes por ano para o horizonte de 10 anos. Para este investimento, é estimado que o acréscimo na fatura de um consumidor que esteja na faixa de 250KWh a 300KWh por mês é aproximadamente de R\$0,30 por mês.

Após, é feita a análise da melhor tarifa otimizada, considerando investimentos

para expansão e qualidade da rede utilizando a rede já otimizada pelo SISPAL. Dentro os resultados obtidos por essa análise, destaca-se que em 4 anos os indicadores DEC e FEC podem ser reduzidos pela metade e que o acréscimo na fatura de um consumidor de 300KWh por mês será de R\$0,30 por mês.

Ambos os métodos propostos neste trabalho se mostram eficazes no auxílio ao planejamento para manutenção, expansão e qualidade de fornecimento de energia da rede de distribuição, visando beneficiar tanto a concessionária quanto o bem-estar social.

3.3 Planejamento de Redes de Distribuição Baseado em Métodos de Inteligência Computacional

Nas últimas décadas, houve um aumento significativo na implementação de métodos de inteligência computacional para auxiliar na solução de diversos problemas de engenharia, estatística e até medicina. O uso de inteligências artificiais tem se mostrado bastante eficaz na área de planejamento e também detecção de falhas em sistemas de distribuição. Em muitos casos a melhora dos resultados no planejamento é perceptível e quando não há melhora significativa, o tempo e recurso necessários para obtenção dos resultados é drasticamente reduzido pois não há mais a necessidade de um especialista para formular todo o processo de planejamento. (BERNAL-AGUSTIN, 1998) e (RAMIREZ-ROSADO; BERNAL-AGUSTIN, 1998) mostram estudos comparativos entre algoritmos de inteligência computacional e métodos clássicos de otimização onde são considerados diversos fatores simultâneos como a não-linearidade da função de custo, as faixas de operação de tensão e a confiabilidade do sistema.

No trabalho do Laboratório de Sistemas de Energia Elétrica, Escola de Engenharia de São Carlos (OLESKOVICZ et al., 2006), foi realizado um estudo para comparar modelos de análise, que são utilizados na área da qualidade de energia elétrica. Foram escolhidas três ferramentas: Transformada de Fourier com Janela, Transformada Wavelet e Redes Neurais Artificiais. Esses modelos pretendem detectar, localizar e classificar distúrbios na rede elétrica. Enquanto as Transformadas detectam e localizam tais discontinuidades no sistema agregado às formas de ondas de tensão referenciadas a um sistema real de distribuição, as Redes Neurais são utilizadas para mostrar uma classificação da situação. Basicamente, podemos saber que tipo de distorção ocorreu. Entre elas, o conjunto pode caracterizar 8 situações para cada fenômeno de afundamento e elevação de tensão, interrupção momentânea e transitório oscilatório, além de 10 situações de ruídos sobre o sistema.

(FERREIRA et al., 2009) também propõe algo semelhante utilizando inteligência artificial. Um sistema de detecção e classificação de distúrbios de qualidade de energia elétrica que se baseia na decomposição dos sinais de tensão. Tais distúrbios se caracterizam

como deformações na forma de onda da tensão e corrente no sistema e podem prejudicar as áreas financeiras de muitas indústrias, interrompendo processos de produção e baixando a velocidade nas redes de computadores em geral. O projeto utilizou um algoritmo, que foi baseado na teoria de Bayes, para detectar as falhas e classificar através de redes neurais. Foram realizados testes para algumas classes de distúrbios e estes apresentaram eficiência de 100%. O modelo de sistema foi formado a partir do uso de estatísticas de ordem superior, para detectar e classificar os erros na rede. O classificador utilizado foi uma rede neural perceptron de várias camadas, que é uma estrutura de rede neural composta pela camada de entrada, uma ou mais camadas de neurônios ocultos, e a camada de saída.

Zemite (ZEMITE et al., 2015) propõe um método de análise baseado na SMC e integrado com algoritmos genéticos (GA - *genetic algorithms*) para encontrar soluções otimizadas para diferentes configurações de redes de distribuição, como também diferentes dados da rede, a fim de minimizar custos relacionados ao não-fornecimento de energia elétrica.

São simulados três modelos genéricos de rede de distribuição: uma rede rural, uma rede urbana e uma rede média (ALVEHAG, 2008) e são avaliados os seguintes parâmetros nestes modelos: total de energia não fornecida em KWh, custo total direto, custo total indireto e duração média de falha. Através do uso de algoritmos genéricos o critério de parada de iteração se dá quando os melhores fatores são obtidos e não sofrem mudanças durante 15 gerações.

Em um primeiro momento, o algoritmo busca minimizar os custos de interrupção e aumentar a confiabilidade do sistema tentando encontrar um número mínimo de interruptores de alimentação e seccionadores na rede. Após, são estudados a viabilidade de investimento de capital para diminuir custos de perdas diretas e indiretas visando aumentar a confiabilidade do sistema, avaliando a possibilidade de empréstimos com duração de 10 anos e 25 anos.

Cada simulação e iteração leva em conta os seguintes fatores: a rede de alimentação, energia não fornecida, funções de distribuição de probabilidade de duração de falhas, frequência de falhas nos equipamentos e custos de não fornecimento de energia.

Resultados mostram que a escolha do melhor número de interruptores e seccionadores é importante pois pode reduzir os custos de não-fornecimento em até 33%. Também, o estudo de viabilidade de investimento de capital oferece oportunidades para melhorar os índices de confiabilidade do sistema com o menor investimento possível.

Alguns efeitos podem ocorrer nos sistemas de rede elétrica e prejudicar níveis de tensão, como magnitudes das tesões e simetria de fases, e a frequência. Podemos citar como exemplos os afundamentos e/ou elevações de tensão, distorções harmônicas, flutuações de tensão e etc. É importante ter conhecimento desses possíveis erros na rede, para poder controlá-los e evitar prejudicar a qualidade de serviço das distribuidoras

Gómez propõe em (GOMEZ et al., 2004) um sistema de Colônias de Formiga (ACS

- *Ant Colony System*) para o planejamento de sistemas primários de redes de distribuição. ACS são algoritmos que imitam o comportamento de colônias de formigas quando estão em busca de alimentos. Durante a expedição de busca, cada indivíduo libera feromônios para marcar o caminho está sendo utilizado, guiando assim os próximos exploradores a fonte de alimentos. Assim, o caminho mais curto tende a ter o maior teor de feromônio e então será escolhido pelos próximos exploradores. Os princípios básicos do ACS foram adaptados ao problema de otimização de planejamento de sistemas primários de redes de distribuição em conjunto com um módulo de fluxo de potência considerando condições de cargas máximas.

O sistema avalia parâmetros como faixa de operação de tensão, custos operacionais, custos dos equipamentos, custos incrementais pela adição de novos ramos a rede (em \$/kVA) e também uma métrica de potência aparente vezes o comprimento do trecho considerado (em kVAm). A estratégia é testada com dois circuitos distintos, o primeiro é uma pequena rede de 34,5kV e 10MVA com 23 nós e o segundo circuito é uma rede maior e mais complexa de 10kV e 10MVA. Os resultados são obtidos por sugestões de configurações de redes, apresentando adicionalmente o custo relacionado a perdas (por energia não distribuída) e o custo de investimento por cada trecho considerado.

Por fim, pode-se perceber através dos trabalhos discutidos que o planejamento é de extrema importância para as concessionárias e que a otimização destas estratégias pode trazer melhorias para o sistema no médio e longo prazo.

Destaca-se que até o momento, a literatura não apresenta muitos trabalhos quanto ao uso de métodos de inteligência computacional para o auxílio no planejamento de redes de distribuição.

4 SÉRIES TEMPORAIS

Uma série temporal é um grupo de observações, sobre determinada variável, ordenado no tempo, de acordo com (REIS, 2016). As séries temporais podem ser interpretadas como o registro histórico de determinadas atividades ao longo do tempo, como por exemplo: quantidade de vendas de uma empresa ao longo do ano, valores mensais do nível pluviométrico de uma cidade, consumo de energia mensal em um local, variação da carga de uma rede de distribuição no dia, variação do preço de uma ação no mercado financeiro.

A análise de uma série temporal é instrumento fundamental em diversas áreas do conhecimento como estatística, economia, física e engenharias. A análise do comportamento da vazão de um rio ao longo dos anos, estudos da variação dos níveis de vendas de uma empresa, análise da curva de carga de um sistema de potência, entre outros, são exemplos de situações que necessitam que seja feita um estudo analítico das séries temporais em questão.

Saber a forma que seus dados se comportam é muito vantajoso para investimentos, planejamentos estratégicos e métodos de apoio à tomada decisão, pois estudando os valores passados de uma variável, é possível construir um modelo aproximado para que sejam feitas previsões. Dessa forma, muitos pesquisadores e especialistas utilizam a análise de séries temporais como forma de extração de conhecimento a respeito de uma variável.

Uma série temporal pode ser explicada através das seguintes características:


- Tendência: comportamento da série a longo prazo, padrão de crescimento/descrescimento dos dados.
- Ciclos: flutuações cíclicas dos valores de forma não periódica.
- Sazonalidade: flutuações dos valores que ocorrem em um determinado período, ou seja, as flutuações ocorrem em períodos regulares, repetindo com o passar do tempo.
- Valores irregulares: oscilações aleatórias e inexplicáveis.

Os comportamentos de sazonalidade e tendência podem dizer se uma série é ou não estacionária. Uma série estacionária é aquela onde os valores flutuam no entorno de uma média constante. Logo, uma série que possui sazonalidade e/ou tendência deixa de ser estacionária.

A Figura 1 (venda de milhares de litros de vinho ao mês) ilustra um exemplo série temporal. Nela, podemos observar uma sazonalidade anual e a ausência de tendência.

Figura 1 - Exemplo de série temporal

Fonte: (DATA...,)



4.1 Modelos de Previsão de Séries Temporais

Ao analisar e identificar padrões nos dados, podemos formular um modelo matemático, ou seja, uma representação aproximada da série temporal. No decorrer das últimas décadas, diversos métodos foram formulados para identificar padrões nos dados, realizar previsões de valores futuros e modelar analiticamente uma série temporal.

Como uma série temporal considera apenas seus dados históricos, sempre haverá uma parcela de valores irregulares que a primeira vista podem parecer totalmente aleatórios. Além disso, padrões de tendência e sazonalidade podem não estar explícitos, ou claros. Assim, se buscam modelos de previsão que possam se aproximar com mais precisão da série de dados reais.

Após a identificação comportamental, verificando a existência das características mencionadas anteriormente, como sazonalidade e tendência, podemos escolher o modelo que melhor se adequa, para obter um bom resultado de previsão.

No que tange a quantidade de variáveis que podem constituir um modelo, temos a seguinte classificação:

- **Univariados:** modelos que se baseiam apenas em valores históricos de uma série.
- **Causais:** modelos que se baseiam em valores históricos da própria série e de outras relacionadas.

- Multivariados: modelos que são capaz de prever mais de uma série.

Também é possível classificar os modelos quanto a sua forma de decomposição. Assim, consideramos a decomposição do modelo comportamental através das características da série. Existem dois tipos de modelos de decomposição: o modelo aditivo ((7)) e o multiplicativo ((8)).

$$Y = T + S + C + I \quad (7)$$

$$Y = T \times S \times C \times I \quad (8)$$

Onde: T = tendência da série, S = sazonalidade da série, C = ciclos da série, I = irregularidade da série,

Através da escolha da decomposição, é possível descobrir os ciclos e irregularidades a partir da remoção das características anteriores, como podemos ver nas equações (9) e (10) (REIS, 2016).

$$CI = Y - T - S \quad (9)$$

$$CI = \frac{Y}{T \times S} \quad (10)$$

Entre os modelos mais simples e diretos está o modelo de médias móveis (MA - *Moving Average*), ou métodos dos mínimos quadrados, que é utilizado para descobrir a tendência e índices sazonais de uma série.

Já os modelos de suavização exponencial, declaram que os valores extremos das séries apresentam aleatoriedade. Por isso, entende-se que com a suavização desses extremos, é possível encontrar um padrão melhor para a modelagem da série. Os métodos mais conhecidos de suavização exponencial são: Suavização Exponencial simples e Holt-Winters. Geralmente, utilizamos a suavização simples para séries sem tendência, enquanto o método de Holt e Holt-Winters se mostra mais adequado para séries com tendência e/ou sazonalidade (WERNER, 2017).

Além destes modelos, temos o modelo auto-regressivo integrado de médias móveis (ARIMA - *Auto Regressive Integrate Moving Average*), que tem sido largamente utilizado para previsão de séries temporais. Este modelo foi proposto por Box e Jenkins em 1970 (BOX; JENKINS; REINSEL, 2008) e é uma extensão do modelo auto-regressivos de

médias móveis (ARMA - *Auto Regressive Moving Average*). Enquanto os modelos auto-regressivo (AR - *Auto Regressive*), médias móveis e ARMA são considerados para séries estacionárias, o modelo ARIMA é escolhido para situações com séries não-estacionárias.

De acordo com (GUTIÉRREZ, 2003), o termo auto-regressivo (AR) está ligado a defasagem da série que foi transformada. As médias móveis (MA) são ligadas a defasagens dos erros aleatórios e o termo integrado (I) se refere ao processo de diferenciação da série original para torná-la estacionária.

O modelo AR é apresentado na (11) e pode ser ajustado pelo parâmetro p , que na verdade é o grau de seu polinômio.

$$Z(t) = \mu + \phi Z_{t-1} + \cdots + \phi_p Z_{t-p} + \varepsilon_t \quad (11)$$

O modelo MA é apresentado na (12) e pode ser ajustado pelo parâmetro q , que também é o grau de seu polinômio.

$$Z(t) = \mu + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} + \varepsilon_t \quad (12)$$

Já o modelo ARMA é definido pela união entre a (11) e (12) e é apresentado na (13). Sendo assim, este modelo possui dois parâmetros ajustáveis p e q (MARASCA; DAPPER, 2017).

$$Z(t) = \mu + \phi Z_{t-1} + \cdots + \phi_p Z_{t-p} + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} + \varepsilon_t \quad (13)$$

Por fim, o modelo ARIMA é apresentado na (14). Seus parâmetros ajustáveis são: p , q e d . O parâmetro p é o número de parâmetros auto-regressivos, q é o número de parâmetros de médias móveis e o d é o número de diferenciações necessárias para que a série se torne estacionária.

$$\Delta^d Z(t) = \mu + \phi_1 \Delta^d Z_{t-1} + \cdots + \phi_p \Delta^d Z_{t-p} + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} + \varepsilon_t \quad (14)$$

Logo, para modelar corretamente o modelo ARIMA, é necessário ajustar corretamente os parâmetros p , q e d .

O parâmetro p pode ser obtido através da análise do gráfico da função de autocorrelação amostral, também chamado de ACF (*Auto Correlation Function*). De forma semelhante, o parâmetro q pode ser obtido através da análise do gráfico da função de autocorrelação parcial (PACF - *Partial Auto Correlation Function*). Para a identificação

do parâmetro d , basta diferenciar a série a quantidade de vezes necessária para que a mesma se torne estacionária (elimine sua tendência e sazonalidade).

As funções ACF e PACF analisam o quanto os pontos numa série são dependentes de seus valores passados. É desejado que para uma série estacionária, os valores dos dados tenham a mínima dependência possível de seus valores passados. Os parâmetros p e p são escolhidos com base numa barreira mínima que deve ser atravessada com a regressão da variável no tempo, i.e, a análise começa em t , seguindo para $t-1$, $t-2$ e assim sucessivamente. Caso os valores não decaiam rapidamente, a série pode ser diferenciada e então seu resultado pode ser analisado novamente para a escolha de p e p .

Como mencionado anteriormente, é importante buscar modelos que possam ser capazes de expressar com mais precisão o comportamento de uma série.

Uma das estratégias que têm ganhado mais notoriedade durante os últimos anos é a utilização de redes neurais artificiais para a previsão de séries temporais, pois as mesmas possuem a capacidade de generalização de seus dados de entrada. O capítulo seguinte irá abordar o assunto de redes neurais artificiais com mais detalhes.

5 REDES NEURAIIS ARTIFICIAIS

As técnicas e modelos de inteligência artificial podem auxiliar em diversos campos de atuação de todas as ciências. Tarefas que antes necessitavam da atuação de um especialista o tempo todo, hoje podem ser parcialmente ou até totalmente confiadas a um sistema computacional baseado em inteligência artificial. Podemos ver diversos avanços tecnológicos devido ao uso da inteligência artificial, tais como o diagnóstico antecipado de doenças, automação inteligente de plantas industriais, auxílio na navegação e aviação e sistemas de monitoramento inteligentes.

Na década de 1940, foi projetada a primeira rede neural e desde então, muitas pesquisas surgiram focando nesse tema. Apesar do sucesso por alguns anos, a pesquisa e desenvolvimento desta tecnologia começaram a passar por problemas, como a falta de tecnologia com maior poder de cálculo e carência de conhecimento da estrutura cerebral. A partir de 1980, a área da inteligência artificial voltou a crescer e começou a ser aplicada em situações reais do nosso cotidiano. Isso permitiu um imenso avanço tecnológico, principalmente no campo das ciências exatas (FERREIRA, 2014).

O campo de estudo da inteligência artificial pode ser dividido em problemas de reconhecimento de padrões e problemas de otimização. Problemas de reconhecimento de padrões exploram como um modelo pode entender e estimar resultados de maneira generalizada e não determinística. Problemas de otimização estudam como obter melhores resultados em um processo com a maior eficiência possível.

Redes neurais lidam com o reconhecimento de padrões. Este tipo de problema pode ser dividido em problemas de classificação e problemas de regressão.

Problemas de classificação consistem em construir um modelo que possa avaliar dados, dividi-los em subconjuntos e classifica-los de maneira distinta baseado nas características intrínsecas de cada conjunto. Este tipo de problema pode ser visto em (FERREIRA et al., 2009), como já discutido no Capítulo 3, onde o autor propõe um modelo para identificar padrões de distúrbios na rede.

Problemas de regressão consistem em construir um modelo de aproximação a partir de uma série de dados históricos e tem como objetivo prever os próximos valores dessa série. Em (QUAN; SRINIVASAN; KHOSRAVI, 2014) um sistema baseado em redes neurais é construído para a previsão de carga num sistema de potência a curto prazo.

As redes neurais são estruturas baseadas no funcionamento do cérebro animal. Assim como o cérebro tem a capacidade de se readaptar e mudar de acordo com as circunstâncias, as redes neurais artificiais (RNA) tentam imitar esse comportamento através de um grupo de parâmetros que variam através de processos iterativos em dados analisados. Em outras palavras, pode-se dizer que as RNA interagem e se adaptam com o meio externo por si só.


Destacam-se algumas vantagens da aplicação de RNAs em comparação com outros métodos estatísticos clássicos:

- Capacidade de aprendizado através de métodos de treinamento onde a rede é capaz de construir uma relação entre a entrada e a saída.
- Capacidade da rede de modelar problemas não lineares.
- Capacidade de generalização. Ou seja, a partir de uma quantidade limitada de dados, é possível fazer aferições sobre dados completamente desconhecidos pela rede.

5.1 Modelagem Cognitiva de uma Rede Neural Artificial

Uma rede neural é formada por um conjunto de neurônios artificiais que se comunicam entre si e apresentam entradas e saídas. Primeiramente, vamos considerar o que está apresentado na Figura 5, que apresenta um esquema básico introdutório de funcionamento de apenas um neurônio artificial.

Figura 2 - Neurônio artificial



Seja um conjunto de dados $D = \{x_1, x_2, \dots, x_n\}$ disponível. Este conjunto é inserido e ponderado (multiplicado) por um conjunto de pesos $W = \{w_1, w_2, \dots, w_n\}$. Os pesos podem ser representados como vetores e são o grau de importância que o neurônio dá a cada valor de entrada em relação à saída. Após o somatório ponderado, é inserido um limiar de ativação θ , também chamado de bias, que pode aumentar ou diminuir a importância dos dados de entrada, a fim de ativar um neurônio (SILVA, 2010). Este limiar é convencionado como negativo de acordo com Silva.

Este resultado $u(X, W, \theta)$ passa por uma função de ativação $f(u)$, que adequa à saída y nos limites desejáveis e também pode inserir uma não-linearidade para o modelo (ORTEGA, 2008). Funções de ativação podem ser do tipo parcialmente diferenciáveis,

sendo as principais a função degrau e a função rampa (IRWIN; NELMS, 2011), ou do tipo totalmente diferenciáveis, como a função tangente hiperbólica, a função logística e a função gaussiana (SILVA, 2010)


Podemos resumir o processo de entrada e saída de um neurônio artificial da seguinte maneira:

$$u = \left(\sum_{i=1}^n X(i) * W(i) \right) - \theta \quad (15)$$

$$y = f(u) \quad (16)$$

É importante destacar que um neurônio artificial produz apenas uma saída invariavelmente do número de entradas. Desta maneira, para a obtenção de mais de uma saída, é necessário que haja uma combinação de dois ou mais neurônios artificiais. Esta combinação é chamada de Rede Neural Artificial (RNA). A Figura 3 a seguir apresenta o modelo arquitetural *feedforward* de camada única com n entradas, n neurônios e m saídas.

Figura 3 - Rede *feedforward* camada única



5.2 Taxonomia de Redes Neurais Artificiais

A caracterização de uma RNA pode ser feita através de sua arquitetura, topologia e seu método de aprendizagem.

A arquitetura de uma RNA, caracteriza a maneira como seus neurônios estão dispostos, conectados entre si e também do arranjo de camadas. Existem diversos tipos de arquiteturas de redes, e cada uma é mais adequada a um tipo de problema específico, como reconhecimento de imagens, processamento de imagens, problemas de regressão, etc. Uma RNA pode ser dividida em até 3 camadas, camada de entrada, camada escondida ou intermediária e camada de saída. A camada de entrada consiste dos dados de entrada da rede. A camada escondida é composta de neurônios que extraem características intrínsecas ao processo a ser estudado (SILVA, 2010). Quase todo o processamento da rede é feito nesta camada. A camada de saída também é composta por neurônios e é responsável por apresentar os resultados da rede, que vêm do processamento feito nas camadas anteriores.

Os principais tipos de redes neurais, quanto a sua arquitetura podem ser divididos em: redes *feedforward* de camada única, redes *feedforward* de múltiplas camadas, redes recorrentes e redes reticuladas.

Redes *feedforward* possuem seu fluxo de informação em apenas um sentido, que é da entrada da rede para a saída da mesma. A diferença entre elas é que a rede de camada única apresenta apenas a camada de saída (como ilustrado na Figura 3), e seus neurônios correspondem exatamente ao número de saídas do processo. Já a rede de múltiplas camadas, é constituída de uma ou mais camadas escondidas, que não necessariamente possuirão o mesmo número de neurônios que a saída do processo. As principais redes para estas arquiteturas são as Perceptron de Camada Única, Perceptron Multicamadas (*Multilayer Perceptron* - MLP) e a Rede de Base Radial (também chamada de *Radial Basis Function* - RBF).

Já as redes recorrentes são redes com realimentação da saída nos neurônios de suas camadas intermediárias. A estratégia da realimentação faz este tipo de rede se mostrar bastante adequado para problemas em sistemas dinâmicos, ou também controle de processos. Os principais tipos de redes desta arquitetura são a Rede de Hopfield (VEERASAMY et al., 2018) e também redes Perceptron Multicamada com realimentação em neurônios de camadas distintas.

A topologia de uma rede, diz respeito as suas características específicas, que são escolhidas para resolução de algum problema. Isto é, número de neurônios, número de camadas escondidas, tipo de função de ativação, etc. Por exemplo, uma rede pode ter 10 neurônios em sua camada escondida, 3 neurônios em sua camada de saída e usar a função de ativação tangente hiperbólica.

5.2.1 Rede Neural Perceptron Multicamada


Redes Perceptron multicamadas, ou também *Multilayer Perceptron* (MLP), são apropriadas para a aplicação em diversas áreas de conhecimento tais como, reconhecimento de padrões, otimização de sistemas e também previsão de séries temporais (SILVA, 2010).

A rede MLP pertence a arquitetura *feedforward*. Assim, seu fluxo de informações ocorre apenas em uma direção, que é da entrada para a saída da rede.

Portanto, os dados são inseridos na camada de entrada, seguindo para suas camadas intermediárias e depois para a camada de saída.

A Figura 4 ilustra uma rede MLP que possui sua primeira camada escondida com m neurônios, sua segunda camada escondida com o neurônios e sua camada de saída com p neurônios.

Figura 4 - Rede neural *Multilayer Perceptron*



5.3 Processo de Aprendizagem e Desempenho de uma Rede Neural

Para que uma rede neural atue corretamente, ela deve ser capaz de fazer aferições, com um certo grau de precisão, a respeito de dados a priori desconhecidos. Dessa forma, ela deve passar por três etapas principais: processo de treinamento, ou apenas treino; processo de validação; processo de teste. Os processos de treino e validação podem ser interpretados como o processo de aprendizagem de uma rede neural e o processo de teste como a etapa de desempenho.

O processo de aprendizagem de uma RNA consiste num conjunto de etapas ordenadas para que seus parâmetros sejam ajustados. Dessa maneira, espera-se que a rede seja capaz de generalizar o problema e gerar bons resultados a partir de um conjunto de amostras retiradas do contexto estudado (conjunto de treino).

Entre os tipos de aprendizagem existentes, podemos citar os principais: treinamento supervisionado e treinamento não-supervisionado.

O treinamento supervisionado consiste na comparação dos dados de saída da rede com os dados reais, através de alguma função de erro, e assim são feitos ajustes graduativos nos pesos da rede. Por outro lado, o treinamento não-supervisionado deixa a rede encontrar padrões nos dados apresentados, não oferecendo nenhum tipo de resultado esperado.

O processo de ajuste dos parâmetros de uma rede durante a aprendizagem varia de acordo com a arquitetura de uma rede e também do tipo de problema a ser resolvido. Por exemplo, para uma rede do tipo Perceptron Multicamada, é utilizado o algoritmo de *back-propagation* durante o aprendizado supervisionado. Neste algoritmo, dados de entrada são fornecidos à rede para que a mesma gere sua saída. A saída então é comparada diretamente com a resposta desejada e através dessa diferença, todos os pesos sinápticos da rede são ajustados, começando pela camada de saída, até a camada de entrada. Daí o nome *back-propagation*, pois a propagação da correção do erro acontece de maneira reversa ao fluxo de informações da rede.

Cada iteração deste processo - comparação da saída desejada com valor real e ajuste dos pesos - é denominada de época. São feitas iterações o suficiente para que a rede seja capaz de aprender a respeito dos dados de entrada.

A literatura não apresenta uma regra única que determine o número de épocas ótimo para construir um bom modelo. Porém, existem algumas técnicas, sendo a principal a técnica de parada antecipada.

A parada antecipada, ou *early stopping*, é utilizada para evitar o *overfitting* (sobreajuste) dos pesos da rede neural. O *overfitting* acontece quando a rede passa a se ajustar aos erros e desvios de um conjunto de amostras e começa a perder sua capacidade de generalização do problema. Assim, o algoritmo de *early stopping* monitora uma métrica de comparação entre a saída desejada e a saída obtida (geralmente alguma métrica de erro ou perda de validação). Caso a métrica escolhida pare de decrescer, ou comece a crescer, o treinamento é interrompido. Logo, a consequência desta técnica é a possível interrupção do processo de treinamento antes do número de épocas pré-estabelecido.

Frequentemente, a parada antecipada é feita a partir de um conjunto de validação, que é totalmente independente do conjunto de treino. O conjunto de validação é utilizado para avaliar a capacidade de generalização atual da rede e também efetuar um ajuste fino nos pesos da rede, evitando que a mesma seja sobreajustada ao conjunto de treinamento.

Finalmente, após todo o processo de aprendizagem, a rede neural pode ter seu desempenho avaliado. O desempenho de uma rede neural artificial pode ser medido através de um novo conjunto de dados, geralmente chamado de conjunto de testes. Nesta etapa, já não são feitos mais ajustes nos parâmetros da rede. O conjunto de testes é introduzido na rede e a saída obtida é comparada com a saída real dos dados.

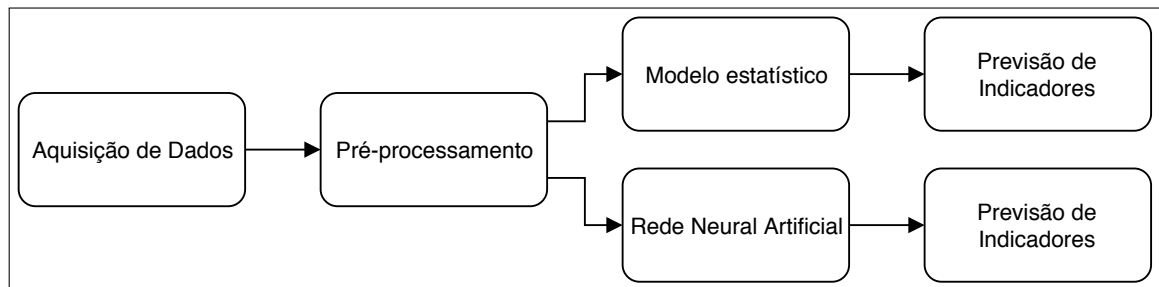
6 METODOLOGIA

Através do que foi discutido no Capítulo 2, percebe-se que deve ser de interesse das distribuidoras atingir as metas propostas pela ANEEL para os indicadores coletivos de continuidade. Em virtude disso, será proposto um sistema que seja capaz de prever valores futuros dos indicadores coletivos de continuidade (DEC e FEC) com um horizonte de 24 meses.

Esta solução é baseada apenas na análise dos valores dos indicadores de continuidade já apurados pela concessionária, ou seja, os dados serão interpretados como séries temporais. Os modelos de previsão escolhidos para tratar este problema foram o modelo ARIMA e a rede neural *Multilayer Perceptron* (MLP). Essa estratégia foi adotada com o intuito de inovar o problema da previsão de dados e também comparar o desempenho de técnicas mais recentes (rede neural MLP para previsão de séries temporais) com métodos mais clássicos, como o modelo ARIMA.

O sistema proposto se encontra na Figura 5.

Figura 5 - Sistema Proposto



Primeiramente, os dados serão adquiridos e serão discutidos qualitativamente numa análise preliminar. Na etapa de pré-processamento será escolhido qual a melhor representação dos dados para cada modelo de previsão. Logo, esta etapa é feita de maneira independente para cada modelo de previsão.

A etapa de pré-processamento é muito importante para aprimorar o desempenho computacional e dos algoritmos usados para análise. O pré-processamento é fundamental para coletar, organizar e tratar os dados, de forma a melhorar sua interpretação para o modelo. De acordo com (SCHMITT, 2005), as principais etapas do pré-processamento são a limpeza de dados, integração de diferentes base de dados, transformação e também redução dos dados. Durante o pré-processamento também são escolhidas as variáveis explicativas para o modelo em questão. Isto é, decidir quais são as variáveis relevantes que devem ser consideradas para a formulação uma boa configuração do modelo de previsão. Por fim, serão apresentados os resultados obtidos pelos modelos de previsão serão discutidos e também comparados através de métricas de desempenho.

6.1 Interpretação Inicial do Conjunto de Dados

Apesar das metas para os indicadores DEC e FEC serem anuais, iremos avaliar os indicadores de acordo com suas apurações mensais. Isto porque diversos fatores podem influenciar tanto no perfil de carga dos consumidores, como nas atividades de manutenção e operação das distribuidoras, ao longo do ano. Podemos citar alguns dos fatores que podem ter influência direta na continuidade de fornecimento de energia elétrica:

- Aumento temporário da tarifa de energia elétrica devido a ocorrência de bandeira amarela ou vermelha (ocorrendo quando há a necessidade de geração termelétrica no Brasil para suprir o sistema).
- Períodos de férias escolares, trabalhistas, épocas festivas e feriados.
- Atividades turísticas.
- Ciclos naturais de chuvas, ventos e variações de umidade e temperatura.
- Estações do ano.

A ocorrência das bandeiras amarela ou vermelha podem fazer com que o consumidor adote um estilo de consumo mais moderado para evitar um valor muito elevado em sua fatura mensal.

Os períodos de férias, feriado e épocas festivas no geral provocam um descolamento considerável das pessoas entre cidades. Da mesma forma acontece com as atividades turísticas. Por exemplo, em cidades turísticas como o Rio de Janeiro, há uma maior concentração de pessoas durante o verão, tanto população local quanto turística.

Já os ciclos meteorológicos naturais podem influenciar nas condições da integridade da rede de distribuição e também nas atividades de manutenção.

Em virtude do que foi mencionado, entende-se que é mais vantajoso analisar os valores mensais dos indicadores ao longo dos anos.

Os indicadores (DEC e FEC) escolhidos para estudo dizem respeito a distribuidora Light SESA. A área de concessão da Light SESA abrange grande parte da região metropolitana e parte do interior do estado do Rio de Janeiro, como mostra a Figura 6.

6.2 Análise Preliminar dos Indicadores Mensais DEC e FEC

Primeiramente, analisemos os indicadores DEC e FEC durante os últimos 17 anos, que se encontram respectivamente nas Figura 7 e Figura 8 .

Nota-se claramente, tanto para o DEC quanto para o FEC, a presença de picos que se encontram entre os meses de dezembro e fevereiro do ano seguinte. Podemos aferir que

Figura 6 - Área de concessão da empresa Light SESA



Fonte: Light Serviços de Eletricidade S. A.

Figura 7 - Indicador DEC de Janeiro de 2000 a Dezembro de 2017





Figura 8 - Indicador FEC de Janeiro de 2000 a Dezembro de 2017



o número maior de interrupções nestes meses acontece devido ao aumento do consumo de energia durante o pico do verão brasileiro, onde em muitos lugares o uso de aparelhos refrigeradores é constante e também é a época da maior atividade turística no Rio de Janeiro. Contrariamente, percebemos que nos meses de inverno (aproximadamente entre junho e agosto) se encontram os valores mais baixos deste indicador. Dessa forma, pode-se afirmar que apenas por uma primeira análise qualitativa há uma sazonalidade presente na série durante o período considerado.

Porém, é interessante notar que em agosto de 2016 houve uma exceção aos padrões percebidos. Nessa época ocorreram os Jogos Olímpicos na cidade do Rio de Janeiro e é perceptível uma elevação dos indicadores em relação a mesma época dos anos anteriores. É importante ressaltar que ao final dos anos de 2009 e 2012 foram apurados os maiores valores para o DEC e o FEC até o momento.

É possível notar que há um decaimento na tendência das séries a partir de 2013 até o final de 2017 (Figura 9 e Figura 10).

Algumas das possíveis causas para a tendência de decaimento dos indicadores podem ser:

- Aumento do número de atividades de manutenção de equipamentos;
- Aumento do número de atividades de podas de árvores que interferem na rede aérea primária da concessionária;
- Interligação de trechos da rede;
- Inserção de equipamentos de religamento por comando remoto e/ou automáticos;
- Inserção de equipamentos para seccionalizar mais trechos da rede.

Figura 9 - Indicador DEC de Janeiro de 2011 a Dezembro de 2017





Figura 10 - Indicador FEC de Janeiro de 2011 a Dezembro de 2017



Porém, não podemos afirmar com plena certeza, pois utilizamos apenas dados disponíveis em domínio público e estes não incluem os relatórios de manutenção e planejamento das concessionárias.

6.3 Configuração do Modelo ARIMA

O modelo ARIMA foi implementado no software estatístico R Studio através da função "auto.arima". Esta função já executa a normalização dos dados e os parâmetros p , d e q são ajustados de forma automática.

Para o modelo ARIMA, apenas é necessária a escolha de um conjunto de treino e um conjunto de teste. Dessa forma, os dados de entrada para ajuste dos parâmetros p , d e q foram dos anos 2000 a 2015 (216 valores mensais) para ambos os indicadores (DEC e FEC). O conjunto de teste escolhido foram os anos de 2016 e 2017 (24 valores mensais).

É importante mencionar que apesar da divisão na base de dados dos indicadores ser a mesma, a análise para o indicador DEC será feita totalmente independente do indicador FEC. Ou seja, haverá um conjunto de treino para o indicador DEC e outro conjunto de treino para o indicador FEC e será ajustado um modelo ARIMA para cada caso.

6.4 Configuração da Rede Neural MLP

Para a modelagem correta da rede neural MLP é necessário que sejam escolhidas várias relevantes para o problema. A principal variável do problema em questão será a utilização de dados históricos da própria série como entrada da rede.


Para que a rede MLP seja treinada com o objetivo de prever os valores futuros, é necessário implementar a técnica de janelamento. Esta técnica consiste em utilizar valores históricos imediatamente anteriores ao valor presente como entrada principal para a rede neural, de maneira que o valor presente da série é o valor desejado na previsão. A figura Figura 11 pode ilustrar melhor esta técnica, onde 5 últimos dados são usados como entrada da rede, um valor é previsto um passo a frente e é feito um ajuste baseado na comparação entre o alvo e a previsão.

Obviamente, será utilizado o método de treinamento supervisionado com o algoritmo de *back propagation* (conceitos previamente apresentados no Capítulo 5) pois é necessário comparar o valor previsto com o valor real e ajustar os pesos da rede neural.

Além das janelas anteriores ao valor presente da série, também será considerado no nosso modelo o valor do mês do alvo da previsão.

Todos os dados da série histórica serão normalizados, como também os valores dos meses do ano.

Figura 11 - Técnica de janelamento para redes neurais



Fonte: (CâMARA, 2016)

Para o indicador DEC, foi considerado uma janela de 7 valores mensais anteriores ao valor presente como entrada principal. Já para o indicador FEC, foi considerado uma janela de 6 valores mensais anteriores ao valor presente como entrada principal. Vale ressaltar que foi aplicada uma operação de diferenciação nos dados para que fosse removida as tendências e sazonalidade.

Como o horizonte de previsão será de 24 meses, é necessário que seja feita uma previsão em multi-estágios. A previsão em multi-estágios consiste em utilizar a previsão imediata do dado como parâmetro de entrada na rede para que sejam feitas previsões em mais passos. Assim, serão feitas 11 iterações em multi-estágios para a previsão de 24 meses a frente.

Para ambos os indicadores foi considerado um conjunto de treinamento dos anos 2007 até o ano de 2015 (108 dados mensais por indicador). 20% do conjunto de treinamento (últimos 22 dados mensais) foi separado para validação. O conjunto de teste constituiu os anos de 2016 e 2017 (24 dados mensais).

A topologia da rede neural para a previsão do indicador DEC constitui 3 camadas escondidas com 13 neurônios respectivamente, sendo suas funções de ativação a função ReLU (*rectified linear unit*), e um neurônio na camada de saída com a função de ativação linear.

A topologia da rede neural para a previsão do indicador FEC também constitui 3 camadas escondidas com 13 neurônios respectivamente, sendo suas funções de ativação a

função ReLU (*rectified linear unit*), e um neurônio na camada de saída com a função de ativação linear.

Foi utilizada a linguagem Python (versão 3.5) juntamente com a biblioteca da Google, TensorFlow (versão 1.8) para a construção da rede neural e toda a etapa de pré-processamento apresentada.

6.5 Avaliação de Resultados

Os seguintes erros serão usados para avaliação dos resultados obtidos pelos modelos de previsão: raiz quadrada do erro quadrático médio (RMSE - *Root Mean Squared Error*) e o erro médio absoluto percentual (MAPE - *Mean Absolute Percentage Error*).

O RMSE pode ser definido por:

$$RMSE = \sqrt{(x - y)^2} \quad (17)$$

O MAPE pode ser definido por:

$$MAPE = \sqrt{|x - y|/y} \quad (18)$$

Essas métricas são importantes para comparar o quão próximo uma previsão feita se encontra de seus dados reais.

Além disso, as previsões feitas serão apresentadas em forma de gráficos e analisadas qualitativamente.

7 RESULTADOS

Neste capítulo serão mostrados os resultados dos modelos utilizados neste trabalho. Em cada software foram gerados gráficos e calculados os erros, a fim de analisar e comparar as previsões. Os resultados de cada modelo serão mostrados separadamente, analisando seus respectivos erros e gráficos que apresentam as previsões de 2016 e 2017 dos indicadores. Após, uma comparação entre os modelos será feita na última seção desse capítulo.

7.1 Resultados do Modelo ARIMA

Os parâmetros ajustados (p, d, q) no modelo ARIMA foram de $(3,0,0)$ e $(1,0,0)$ para os indicadores DEC e FEC respectivamente. Suas previsões encontram-se na Figura 12 e Figura 14. No modelo ARIMA observa-se, de acordo com a Figura 13 e a Figura 15, uma dificuldade de alcançar os picos e valores exatos da séries originais, porém as previsões conseguem simular, de forma satisfatória, o comportamento dos dados prevendo suas sazonalidades e seus ciclos. O valor do MAPE, observado na Tabela 1, está um pouco alto, mas é aceitável levando em consideração a dificuldade apresentada anteriormente.

Figura 12 - Comparação entre a previsão com o Modelo ARIMA e os valores reais do indicador DEC




Figura 13 - Comparação entre a previsão com o Modelo ARIMA e os valores reais do indicador DEC - intervalo de 2013 a 2017




Figura 14 - Comparação entre a previsão com o Modelo ARIMA e os valores reais do indicador FEC

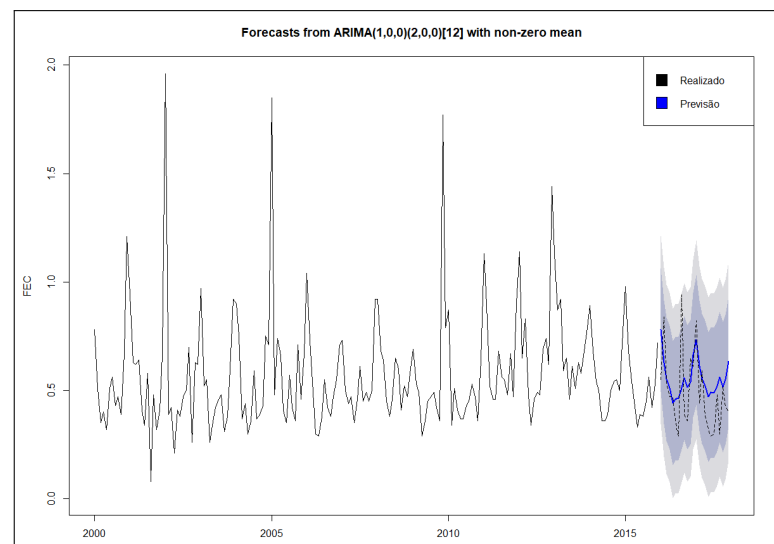



Tabela 1 - Previsão do modelo ARIMA

	MAPE	RMSE
DEC	38.51	0.39
FEC	32.74	0.17

Figura 15 - Comparação entre a previsão com o Modelo ARIMA e os valores reais do indicador FEC - intervalo de 2013 a 2017



7.2 Resultados do Modelo de Redes Neurais

Para ambos os indicadores (DEC e FEC), o modelo ajustado foi de 3 camadas escondidas com 12 neurônios cada uma e um janelamento de 13 valores defasados.

As variáveis explicativas para a rede foram 13 observações de valores passados da série, com sua sazonalidade e tendência removida através da diferenciação, e também a informação do mês alvo de previsão.

As previsões se encontram na Figura 16 e na Figura 17.

Figura 16 - Comparação entre previsão com a rede MLP e os valores reais do indicador DEC






Figura 17 - Comparação entre previsão com a rede MLP e os valores reais do indicador FEC



Analisando o indicador DEC, vemos que a maior dificuldade da rede neural foi acompanhar os valores nos respectivos meses, pois na maior parte da série há uma defasagem de um mês da previsão em relação ao valor real. Dessa forma, a previsão encontra-se um mês atrasada em relação aos valores reais apurados, como pode ser melhor observado na Figura 18.


Figura 18 - Comparação entre previsão com a rede MLP e os valores reais do indicador DEC - intervalo de 2013 a 2017



Para o indicador FEC, a mesma situação da defasagem de um mês ocorre, como pode ser melhor observado na Figura 19. É válido mencionar que no final de 2017 os dados apresentam um padrão diferente da maioria dos anos anteriores, ou seja, na maioria dos anos anteriores, durante os últimos meses do ano ocorre uma elevação na apuração do indicador FEC, porém em 2017 ocorre o oposto.

Na Tabela 2 são apresentados os erros MAPE e RMSE em relação ao conjunto

Figura 19 - Comparação entre previsão com a rede MLP e os valores reais do indicador FEC - intervalo de 2013 a 2017



de testes. Entendemos que os valores elevados dos erros devem-se majoritariamente a defasagem da previsão em relação ao dados reais.

Tabela 2 - Previsão do modelo de Redes Neurais

	MAPE	RMSE
DEC	40.90	0.49
FEC	43.61	0.25

7.3 Comparação entre os modelos

Analisando a previsão efetuada pelos modelos propostos através de seus erros (RMSE e MAPE), percebemos que o modelo ARIMA possui uma leve vantagem no desempenho quando comparado com a rede MLP.

Tabela 3 - Comparação entre Previsões DEC

	MAPE	RMSE
Rede MLP	40.90	0.49
ARIMA	38.51	0.39

Tabela 4 - Comparação entre Previsões FEC

	MAPE	RMSE
Rede MLP	43.61	0.25
ARIMA	32.74	0.17

8 CONCLUSÕES

Neste trabalho de conclusão de curso foram analisados os comportamentos históricos dos indicadores coletivos de continuidade DEC e FEC, a fim de conseguir prevê-los em um horizonte de 1 ano. Com a utilização do modelo estatístico ARIMA e da rede neural Perceptron Multicamada foi possível construir modelos para a previsão das séries temporais dos indicadores DEC e FEC.

Através dos resultados obtidos, concluímos que é considerado um desafio conseguir uma previsão mais exata, por diversos fatores como mudanças nas leis que vigoram no país e também definições criadas pela ANEEL.

Dessa maneira, desde a criação dos indicadores de continuidade, a ANEEL vem atualizando periodicamente suas definições e metodologias para o estabelecimento de metas para as concessionárias.

É importante mencionar que, o maior obstáculo encontrado para a construção do modelo de dados foi a indisponibilidade de dados adicionais a respeito da concessionária e de sua rede de distribuição. De acordo com os trabalhos discutidos no Capítulo 3, informações a respeito das atividades de manutenção de equipamento, investimentos para a expansão e melhoria da rede de distribuição e também atividades de podas de árvore, poderiam ser utilizados como dados de entrada para rede neural MLP. Assim, apenas os dados das séries históricas dos indicadores coletivos de continuidade foram utilizados como variáveis de entrada.

Apesar disso entendemos que os resultados obtidos possam ser utilizados de forma qualitativa e que a metodologia proposta consiga auxiliar nas atividades de planejamento a curto e médio prazo.

A fim de melhorar as previsões, seria interessante realizar trabalhos futuros com outros modelos estatísticos de previsão como o modelo SARIMA ou de Holt-Winters, como também modelos de redes neurais mais sofisticados, como a rede LTSM (*Long Short-Term Memory*).

Esta arquitetura de rede utiliza blocos de memória ao invés de neurônios convencionais (HOCHREITER; SCHMIDHUBER, 1997). Cada bloco de memória é responsável por "lembrar" de valores com o passar do tempo. Assim, com a configuração de diversos blocos é possível perceber padrões de longo prazo em uma série temporal.

Além disso, acreditamos que outros estudos podem ser feitos a respeito de como as atividades periódicas de manutenção de equipamentos impacta na apuração dos indicadores de continuidade, como também avaliar a projeção dos investimentos para melhoria do sistema de distribuição e seus impactos na qualidade de serviço.

REFERÊNCIAS

- ALVEHAG, K. Impact of dependencies in risk assessments of power distribution systems. *DIVA*, 2008.
- ANEEL. *Nota Técnica n 0181/2013-SRD/ANEEL*. [S.l.], 2013. Disponível em: <http://www2.aneel.gov.br/aplicacoes/audiencia/arquivo/2013/089/documento/nota_tecnica_0181_srd_dec-fec_light.pdf>.
- ANEEL. *PRODIST - Módulo 8 – Qualidade da Energia Elétrica*. [S.l.: s.n.], 2018.
- BERNAL-AGUSTIN, J. L. *Aplicación de Algoritmos Genéticos al Diseño Optimo de Sistemas de Distribución de Energía Eléctrica*. Tese (PhD Thesis) — Universidad de Zaragoza, Espanha, 1998. Disponível em: <<https://www.calameo.com/books/0047881277c9dd86ecace>>.
- BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C. *Time Series Analysis: Forecasting and Control*. 4 edition. ed. Hoboken, N.J: Wiley, 2008. ISBN 978-0-470-27284-8.
- Brasil. *Lei das Concessões de Serviços Públicos; Lei de Concessões; Lei Geral das Concessões*. [S.l.: s.n.], 1995.
- CÂMARA, R. *Previsão de Séries Temporais do Montante de Recarga de Celulares Pré-Pagos Baseada em Redes Neurais Artificiais*. Tese (Doutorado) — PUC-Rio, out. 2016.
- CYRILLO, I. O. *Estabelecimento de metas de qualidade na distribuição de energia elétrica por otimização da rede e do nível tarifário*. Tese (text) — Universidade de São Paulo, abr. 2011. Disponível em: <<http://www.teses.usp.br/teses/disponiveis/3/3143/tde-19072011-102800/>>.
- DATA Mining na Prática: Time Series. Disponível em: <<https://www.devmedia.com.br/data-mining-na-pratica-time-series/5414>>.
- DIAS, E. B. *Avaliação de indicadores de continuidade e seu impacto no planejamento de sistemas de distribuição*. Tese (text) — Universidade de São Paulo, abr. 2002. Disponível em: <<http://www.teses.usp.br/teses/disponiveis/3/3143/tde-12062003-173042/>>.
- DIAS, E. B.; MANHÃES, L. R.; OLIVEIRA, C. C. B. de. Implementação e Resultados de um Novo Modelo de Análise e Previsão de Confiabilidade de Redes Primárias na CPFL. XVI SENDI, 2004. Disponível em: <www.mfap.com.br/pesquisa/arquivos/20081029162930-Trabalho%20-%20529.doc>.
- DIEESE. *Privatização, desnacionalização e terceirização do setor elétrico brasileiro*. [S.l.], 2017. 19 p. Disponível em: <<https://www.dieese.org.br/notatecnica/2017/notaTec173PrivatizacaoSetorEletrico.pdf>>.
- DNAEE. *PORTARIA Nº 46, DE 17 DE ABRIL DE 1978*. [S.l.: s.n.], 1978.
- FERREIRA, D. D. et al. Sistema automático de detecção e classificação de distúrbios elétricos em qualidade da energia elétrica. *Sba: Controle & Automação Sociedade Brasileira de Automatica*, v. 20, n. 1, p. 53–62, mar. 2009. ISSN 0103-1759.

FERREIRA, M. M. A. NOÇÕES DE REDES NEURAIS ARTIFICIAIS. p. 29, 2014.

GOMEZ, J. F. et al. Ant colony system algorithm for the planning of primary distribution circuits. *IEEE Transactions on Power Systems*, v. 19, n. 2, p. 996–1004, maio 2004. ISSN 0885-8950.

GUTIÉRREZ, J. L. C. Monitoramento da Instrumentação da Barragem de Corumbá-I por Redes Neurais e Modelos de Box & Jenkins. p. 146, 2003.

HERNANDO-GIL, I.; ILIE, I. S.; DJOKIC, S. Z. Reliability planning of active distribution systems incorporating regulator requirements and network-reliability equivalents. *Transmission Distribution IET Generation*, v. 10, n. 1, p. 93–106, 2016. ISSN 1751-8687.

HOCHREITER, S.; SCHMIDHUBER, J. Long Short-Term Memory. *Neural Computation*, v. 9, n. 8, p. 1735–1780, nov. 1997. ISSN 0899-7667. Disponível em: <<https://doi.org/10.1162/neco.1997.9.8.1735>>.

IRWIN, J. D.; NELMS, R. M. *Engineering Circuit Analysis*. 10th edition international student version edition. ed. Hoboken, NJ: Wiley, 2011. ISBN 978-0-470-87377-9.

KHATOR, S. K.; LEUNG, L. C. Power distribution planning: a review of models and issues. *IEEE Transactions on Power Systems*, v. 12, n. 3, p. 1151–1159, ago. 1997. ISSN 0885-8950.

MANHÃES, L. R. Programa Para Planejamento de Redes Primárias de Distribuição. n. XIV SENDI, 2000.

MARASCA, L.; DAPPER, S. N. Uma Análise da Volatilidade nas Exportações Brasileiras. p. 10, 2017.

MEHL, E. *Qualidade de Energia Elétrica*. [S.l.], 2001.

NUNES, F. A. Modelo de apoio gerencial para planejamento das ações de manutenção das redes de distribuição de energia elétrica com previsibilidade do impacto nos indicadores de continuidade DEC e FEC: estudo de caso em uma empresa de distribuição no Rio de Janeiro. dez. 2016.

OFGEM, U. *2008/09 Electricity Distribution Quality of Service Report*. [S.l.: s.n.], 2009.

OLESKOVICZ, M. et al. Estudo comparativo de ferramentas modernas de análise aplicadas à qualidade da energia elétrica. *Sba: Controle & Automação Sociedade Brasileira de Automatica*, v. 17, n. 3, p. 331–341, set. 2006. ISSN 0103-1759.

ORTEGA, G. V. C. Redes Neurais na Identificação de Perdas Comerciais do Setor Elétrico. p. 21, 2008.

PEA. *Annual Report 2014 EN*. [S.l.: s.n.], 2014.

QUAN, H.; SRINIVASAN, D.; KHOSRAVI, A. Short-Term Load and Wind Power Forecasting Using Neural Network-Based Prediction Intervals. *IEEE Transactions on Neural Networks and Learning Systems*, v. 25, n. 2, p. 303–315, fev. 2014. ISSN 2162-237X.

RAMIREZ-ROSADO, I. J.; BERNAL-AGUSTIN, J. L. Genetic algorithms applied to the design of large power distribution systems. *IEEE Transactions on Power Systems*, v. 13, n. 2, p. 696–703, maio 1998. ISSN 0885-8950.

REIS, M. M. Análise de séries temporais. p. 55, 2016.

SCHMITT, J. PRÉ-PROCESSAMENTO PARA A MINERAÇÃO DE DADOS: USO DA ANÁLISE DE COMPONENTES PRINCIPAIS COM ESCALONAMENTO ÓTIMO. p. 147, 2005.

SILVA, I. N. d. *Redes Neurais Artificiais Para Engenharia E Ciências Aplicadas. Curso Prático*. [S.l.]: Artliber, 2010. ISBN 978-85-88098-53-4.

TRAGOONTHAI, S.; CHAITUSANEY, S. Optimal budget allocation for preventive maintenance of distribution system considering customer outage cost and reliability indices. In: *2017 14th International Conference on Electrical Engineering/Electronics, Computer, Telecommunications and Information Technology (ECTI-CON)*. [S.l.: s.n.], 2017. p. 600–603.

VEERASAMY, V. et al. Load flow analysis using generalised Hopfield neural network. *Transmission Distribution IET Generation*, v. 12, n. 8, p. 1765–1773, 2018. ISSN 1751-8687.

WERNER, L. Utilização de técnicas de previsão para quantidade de leite industrializado no Brasil. p. 9, 2017.

ZEMITE, L. et al. Optimization of distribution systems reliability with the stochastic behavior. In: *2015 56th International Scientific Conference on Power and Electrical Engineering of Riga Technical University (RTUCON)*. [S.l.: s.n.], 2015. p. 1–4.